Yapay Zekâ ve Büyük Veri ile Finans

İSTANBUL TİCARET ÜNİVERSİTESİ

Makineleri Nasıl Akıllandırırız?

Yapay Zekâ ve Makine Öğrenmesine Akademik Giriş

Hazırlayan: Volkan ÖZDEMİR
Danışman: Doç. Dr. Agah Tuğrul KORUCU

Sunumun Amacı

İSTANBUL TİCARET ÜNİVERSİTESİ

Bu sunum sonunda:

- Yapay zekayı teorik ve felsefi düzlemde tanımlayabileceksiniz.
- Makine öğrenmesinin temellerini ve kavramlarını anlayacaksınız.
- Veri kalitesinin model başarısı üzerindeki kritik etkisini analiz etmek.
- Eğitim, doğrulama ve test süreçlerindeki metodolojiyi anlayacaksınız.
- Yapay zeka etiği ve güncel araştırma trendleri hakkında vizyon kazanacaksınız.

İçindekiler

İSTANBUL TİCARET ÜNİVERSİTESİ

- **Yapay Zekâya Giriş:** Tanım, kapsam ve temel mantık.
- **Makine Öğrenmesi (ML):** İstatistiksel öğrenme ve matematiksel temeller.
- **Makine Öğrenmesi Pipeline:** Veriden modele 8 adımda yol haritası.
- **Veri Kalitesi ve Etik:** “Garbage In, Garbage Out” ve algoritmik ayrımcılık.
- **Eğitim ve Performans:** Eğitim-test setleri, aşırı öğrenme, eksik öğrenme ve genelleme.
- **Bilgi Temsili:** Vektör uzayı, embedding, feature space ve latent space kavramları.
- **Model Nasıl “Anlar”?:** İstatistiksel örüntü öğrenme ve tahmin mekanizması.
- **Güncel Araştırmalar:** Açıklanabilir AI, federatif ve öz-denetimli öğrenme.
- **Kritik Tartışma:** Makine gerçekten öğreniyor mu?

Yapay Zekâ Nedir?

İSTANBUL TİCARET ÜNİVERSİTESİ

Yapay Zekâ, bilgisayarlara ve makinelere; öğrenme, anlama, problem çözme, karar verme, yaratıcılık gibi insani bilişsel yetenekleri simüle etmesini sağlayan bir teknolojidir.

Bu sistemler, devasa veri kümelerini analiz eder, kalıpları tanır ve benzeri görülmemiş bir hız ve doğrulukla kararlar alır.

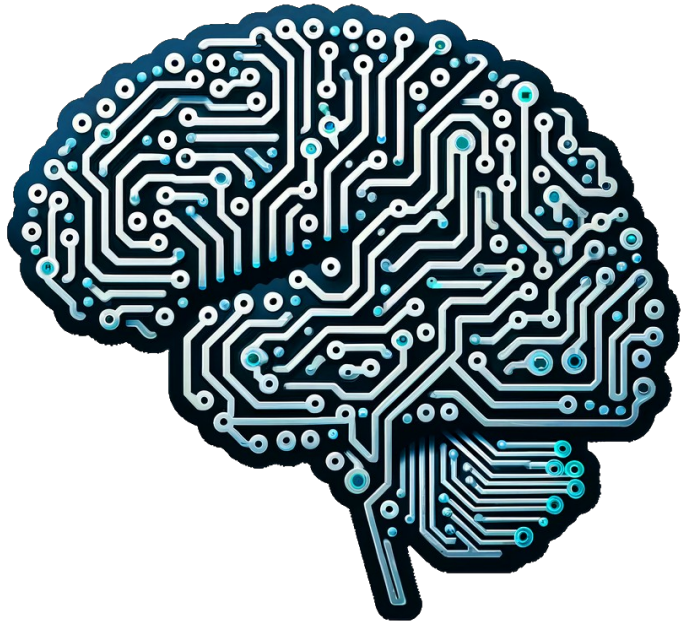

Yapay Zekânın Tarihsel Evrimi

İSTANBUL TİCARET ÜNİVERSİTESİ

Sembolik AI (1950-1980'ler)

Bu dönem genelde yapay zekanın doğuşunu ifade eder ve mühendisler, makinelerin dünyayı anlaması için onlara basit mantık kuralları yazıyordu. Gerçek dünyanın karmaşıklığını ve belirsizliğini kodlamak o zamanlar için imkansızdı.

Temel Mantık: Eğer "A" durumu içerisinde "B" koşulu gerçekleşirse, "C" sonucuna ulaş.

Örnek: Satranç programları veya basit cebir problemleri çözen algoritmalar.

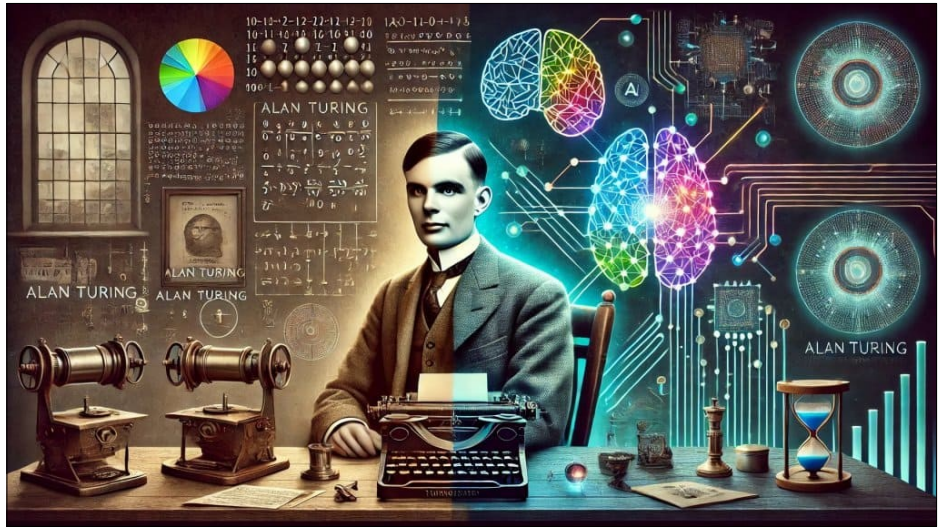

Yapay Zekânın Tarihsel Evrimi

Uzman Sistem (1980'ler)

Uzman bir insanın karar verme yeteneğini simüle etmek üzere tasarlanmış Yapay Zekanın bir dalıdır.

- Doktor, mühendis, avukat gibi insan bilimleri alanında uzmanlaşmış kişiler gibi çalışır.
- Sorunları çözmek için depolanmış bilgileri ve mantıksal kuralları kullanır.
- Tutarlı ve hızlı kararlar verir.
- Çoğunlukla teşhis, sorun giderme ve planlama aşamalarında kullanılır.

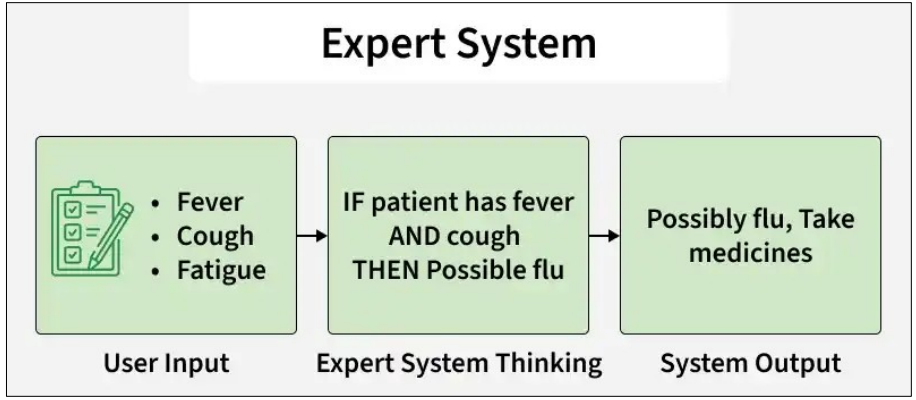

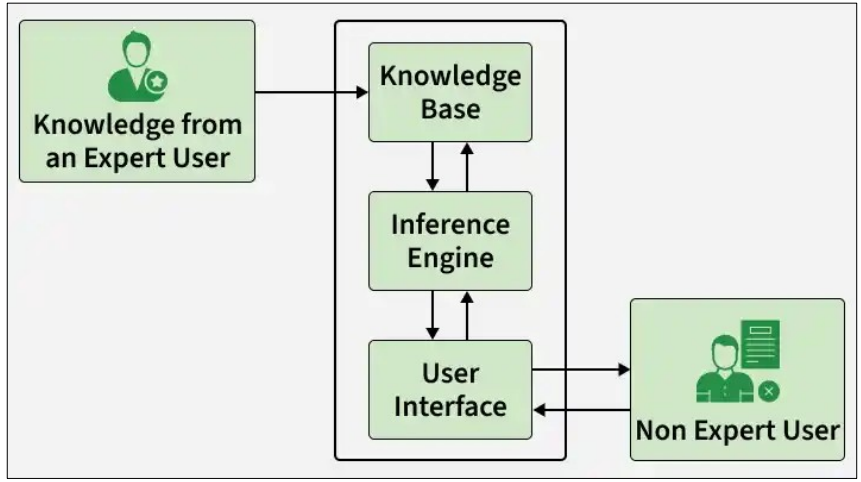

Yapay Zekânın Tarihsel Evrimi

İSTANBUL TİCARET ÜNİVERSİTESİ

İstatistiksel Öğrenme (1990-2000)

Bu dönemde, bilgisayarlara her kuralı öğretmek yerine, onlara veriyi verip kalıpları (pattern) bulmalarını söylemeye başladık.

- Doktor, mühendis, avukat gibi insan bilimleri alanında uzmanlaşmış kişiler gibi çalışır.
- Sorunları çözmek için depolanmış bilgileri ve mantıksal kuralları kullanır.
- Tutarlı ve hızlı kararlar verir.
- Çoğunlukla teşhis, sorun giderme ve planlama aşamalarında kullanılır.

Büyük Veri Dönemi (2000-2010)

İnternetin yaygınlaşmasıyla birlikte elimizde daha önce hiç olmadığı kadar çok veri (metin, görüntü, kullanıcı davranışı) birikti.

Ayrıca, işlemci gücünün artması ve depolama maliyetlerinin düşmesi de bu dönem için büyük bir avantaj oldu.

Sonuç olarak, algoritmalar artık beslenecek devasa bir kaynağa sahip oldu.

Yapay Zekânın Tarihsel Evrimi

İSTANBUL TİCARET ÜNİVERSİTESİ

Derin Öğrenme (2010-Günümüz)

Derin öğrenmenin temelinde, yapay sinir ağları adı verilen matematiksel modeller yer almaktadır. Bu ağlar, insan beynindeki nöronların işleyişinden esinlenerek tasarlanmıştır.

Yapay sinir ağları, çok sayıda katmandan oluşur ve her katman, bir önceki katmandan gelen verileri işleyerek daha karmaşık özellikleri öğrenir.

Kısacası, Geleneksel AI'ya kuralı siz söylersiniz, Derin Öğrenme ise kuralları verinin içinden kendisi çıkarır.

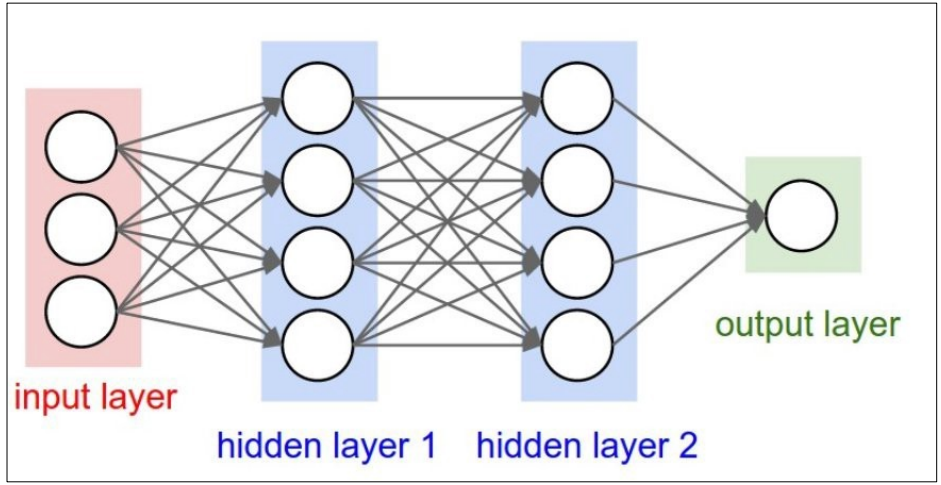

AI – ML – DL İlişkisi

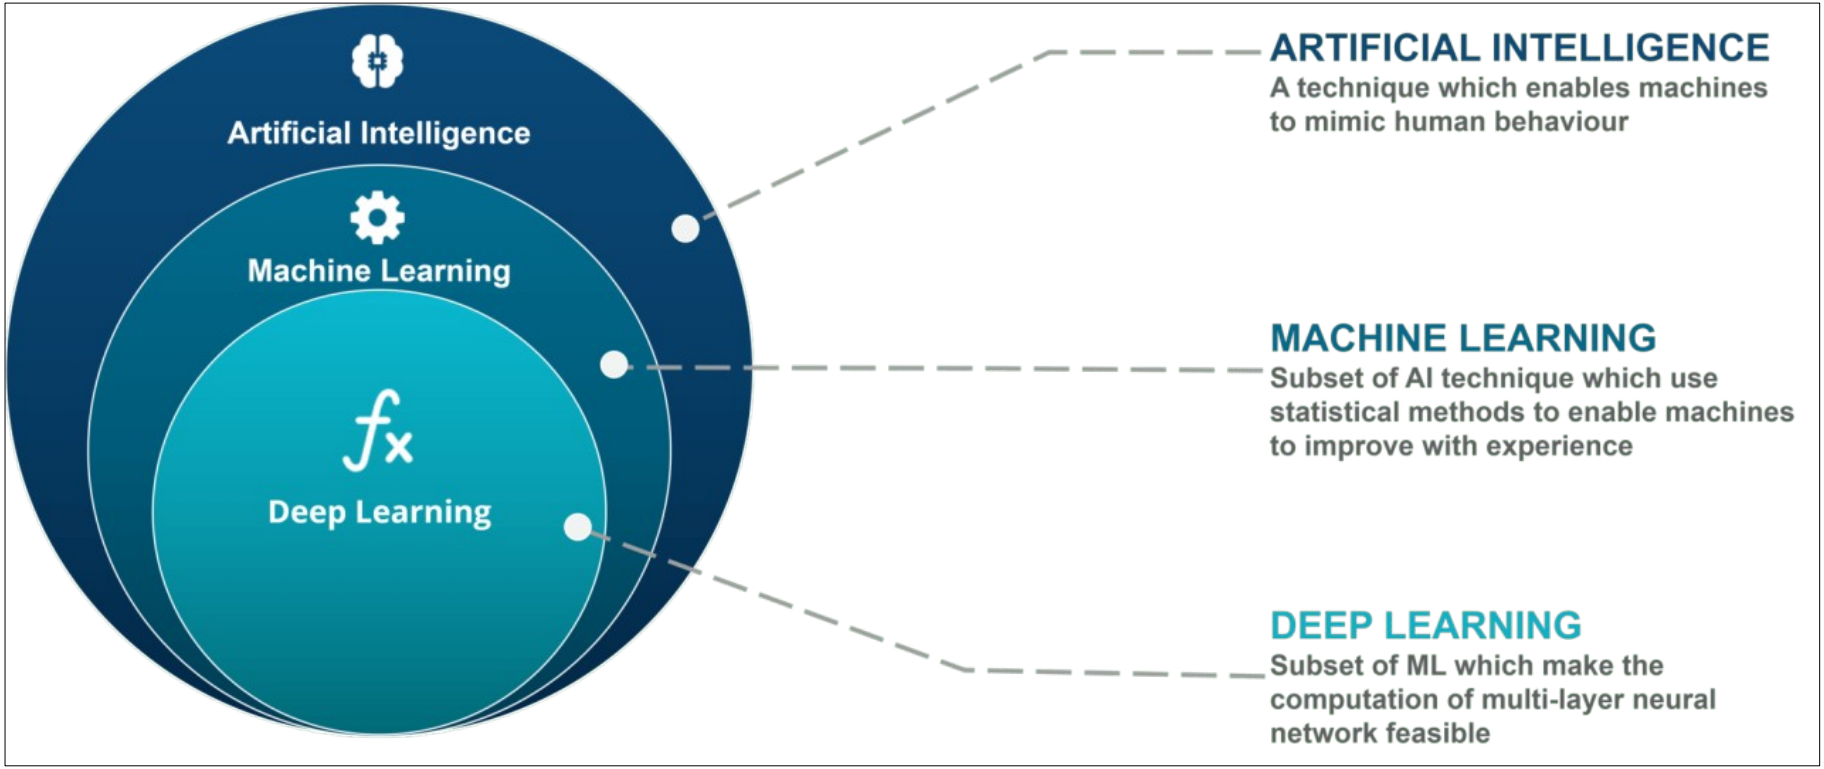

Öğrenme Tanımı (Tom Mitchell)

Bu tanım, makine öğrenmesinin klasik tanımı olup Tom Mitchell tarafından yapılmıştır ve bir sistemin deneyim yoluyla performansını geliştirmesini açıklar. Örneğin;

Bir program;

T görevinde,

P performans ölçütüne göre,

E deneyimi sayesinde performansını artırıyorsa öğrenmiştir.

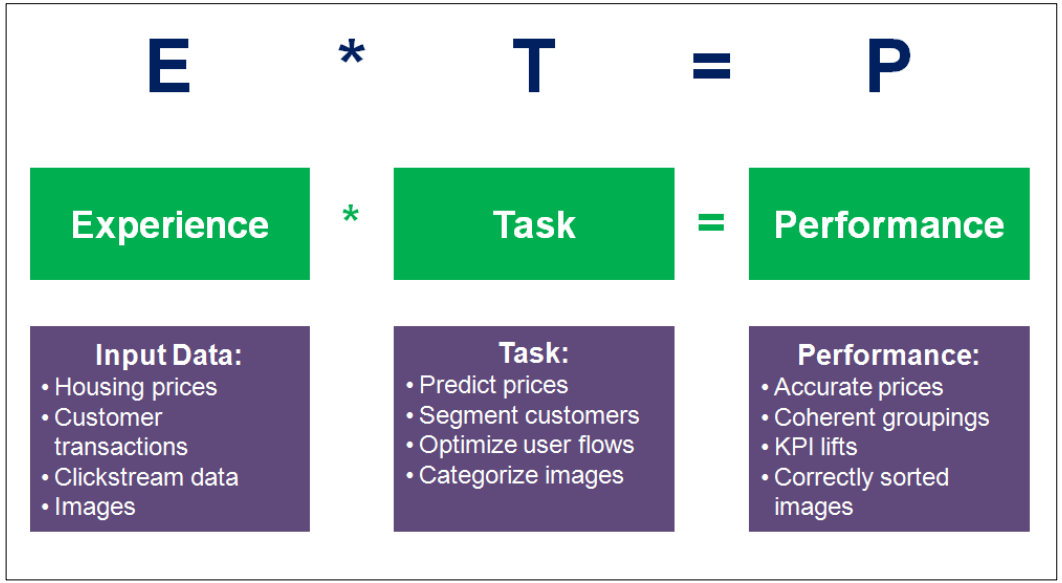

Öğrenme Tanımı (Tom Mitchell)

İSTANBUL TİCARET ÜNİVERSİTESİ

Bu duruma somut bir örnek vermek gerekirse;

Bir spam filtresi düşünelim:

- **T (Task):** E-postayı spam mi değil mi diye sınıflandırmak
- **P (Performance):** Doğru sınıflandırma oranı
- **E (Experience):** Geçmiş normal ve spam e-postaları

Eğer sistem, daha fazla e-posta gördükçe doğruluk oranını arttırıyorsa öğrenmiştir.

ML’in Matematiksel Modeli

İSTANBUL TİCARET ÜNİVERSİTESİ

Makine öğrenmesinde bir modelin nasıl öğrendiğini 3 formülle anlatabiliriz;

1) Amaç
2) Kayıp Fonksiyonu
3) Optimizasyon

1) Amaç

$$f(x) \approx y$$

x : Girdi (veri)

y : Gerçek çıktı

f(x) : Modelin tahmini

Buradaki amaç; Modelin tahmini, gerçek değere mümkün olduğunca yakın olmasıdır.

ML’in Matematiksel Modeli

İSTANBUL TİCARET ÜNİVERSİTESİ

2) Kayıp Fonksiyon

$$L(y, \hat{y})$$

y : Gerçek değer

ŷ : Modelin tahmini

L : Hata miktarını ölçen fonksiyon

Bu, "ne kadar yanlış yaptık?" sorusunun matematiksel cevabıdır.

3) Optimizasyon

$$\min_{\theta} L(f_{\theta}(x), y)$$

θ (theta) : Model parametreleri (ağırlıklar)

Amaç : Hata fonksiyonunu minimum yapmak

Yani model, parametreleri değiştirerek hatayı azaltmaya çalışır.

Öğrenme Paradigmaları

İSTANBUL TİCARET ÜNİVERSİTESİ

Makine öğrenimi paradigmaları, bir algoritmanın veriden bilgiyi nasıl çıkardığını, hangi öğrenme stratejisini izlediğini ve veri ile nasıl etkileşime girdiğini belirleyen temel yaklaşımlardır. Bunlar;

- Denetimli öğrenme
- Denetimsiz öğrenme
- Yarı denetimli öğrenme
- Pekiştirmeli öğrenme

Öğrenme Paradigmaları

İSTANBUL TİCARET ÜNİVERSİTESİ

Denetimli Öğrenme

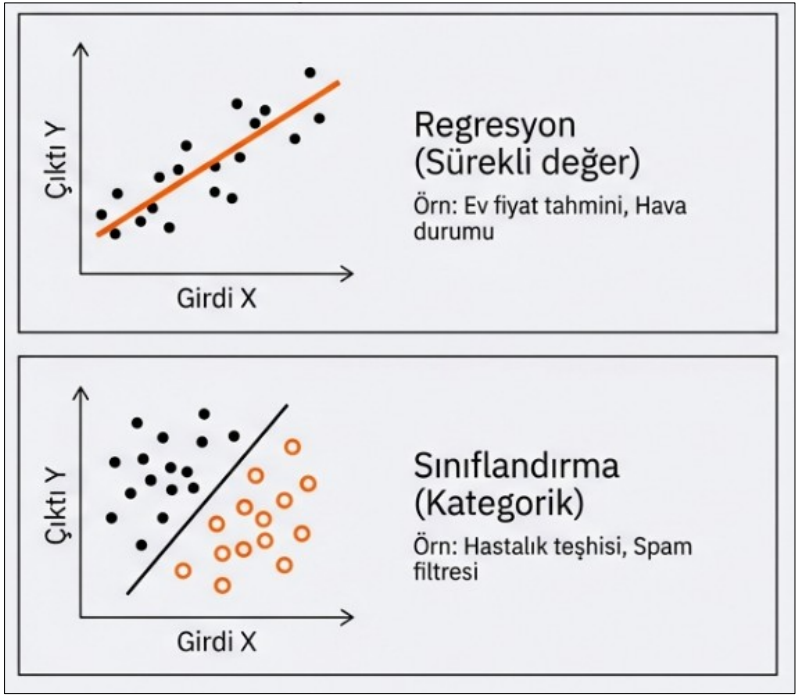

Denetimsiz Öğrenme

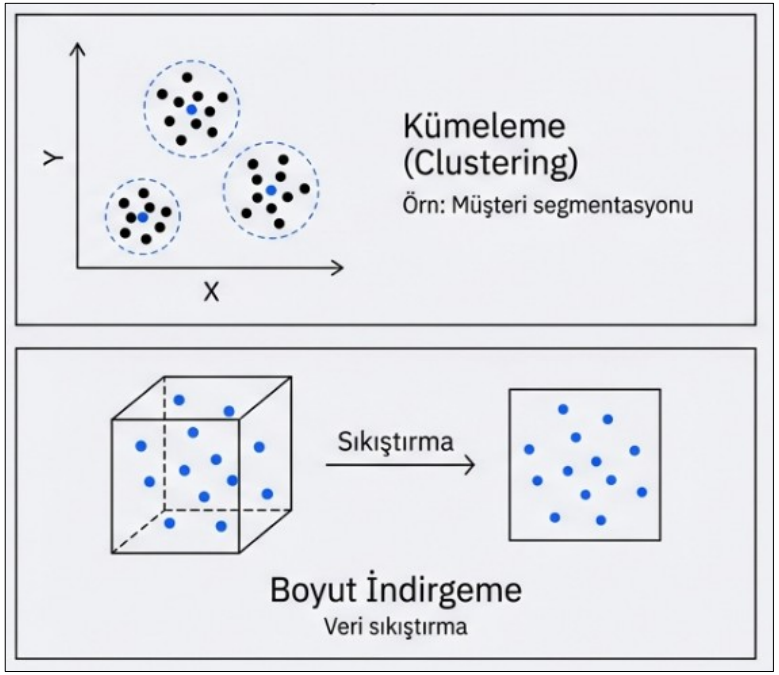

Öğrenme Paradigmaları

Pekiştirmeli Öğrenme

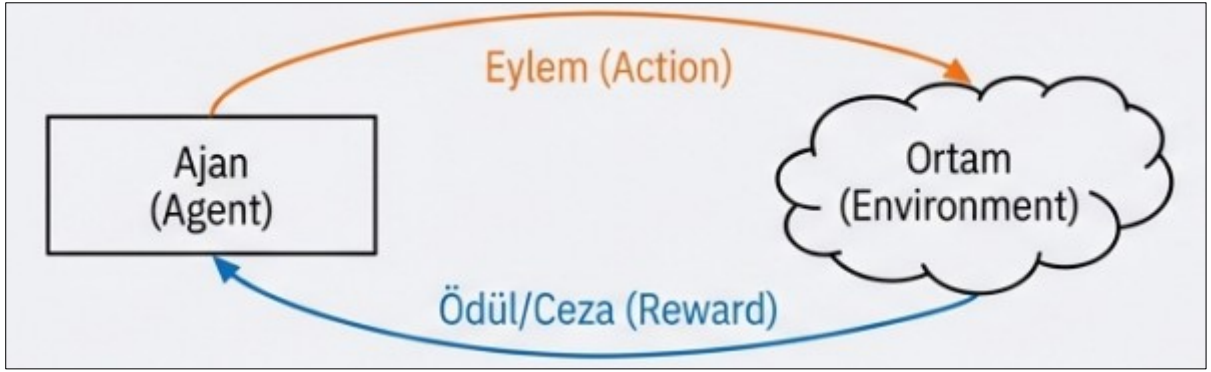

Temel Algoritmalar

- **Linear Regression (Doğrusal Regresyon):** Sürekli bir değişkeni tahmin etmek için girdi ve çıktı arasındaki doğrusal ilişkiyi öğrenir.
- **Logistic Regression (Lojistik Regresyon):** İkili sınıflandırma problemlerinde, bir olayın olma olasılığını tahmin eder.
- **SVM (Support Vector Machine / Destek Vektör Makinesi):** Veriyi sınıflara ayırmak için en geniş sınır çizgisi (hyperplane) bulur.
- **KNN (K-Nearest Neighbors / En Yakın Komşu):** Yeni bir veri noktasını, en yakın komşularının sınıfına göre tahmin eder.
- **Decision Trees (Karar Ağaçları):** Veriyi basit if/else kurallarıyla dallara ayırarak sınıflandırma veya regresyon yapar.
- **Random Forest (Rastgele Orman):** Birden çok karar ağacını birleştirerek daha doğru ve kararlı tahminler yapar.
- **Neural Networks (Yapay Sinir Ağları):** Karmaşık verilerde örüntüleri öğrenmek için çok katmanlı bir yapı ile çalışır, derin öğrenmenin temelidir.

Sinir Ağları (Neural Networks)

$$h(l) = \sigma(W(l)h(l-1) + b(l))$$

Sinir ağları, veriden katman katman özellikler çıkararak karmaşık ve non-lineer ilişkileri öğrenen modellerdir.

Non-lineer modelleme: Karmaşık ilişkileri öğrenebilir.

Hiyerarşik özellik çıkarımı: Alt seviyeden üst seviyeye özellikleri katman katman çıkarır.

Derin Öğrenme Neden Güçlü

İSTANBUL TİCARET ÜNİVERSİTESİ

Derin öğrenme, veriden otomatik özellik çıkarır, büyük veri ile performansını artırır ve görüntü, ses veya metin gibi karmaşık verilerde yüksek başarı sağlar.

- **Otomatik özellik öğrenme:** Özellikleri manuel seçmeye gerek kalmadan veriden öğrenir.
- **Büyük veri ile ölçeklenebilir:** Veri miktarı arttıkça performansı genellikle iyileşir.
- **Görüntü, ses, metin başarısı:** Farklı veri türlerinde üstün sonuç verir.

Derin Öğrenme Neden Güçlü

İSTANBUL TİCARET ÜNİVERSİTESİ

1) **Veri Toplama (Data Collection):** Sürecin yakıtıdır. Sensörler, anketler, veri tabanları veya scraping yoluyla ham veri toplanır.
2) **Veri Temizleme (Data Cleaning):** "Garbage In Garbage Out" (GIGO) prensibiyle; eksik veriler doldurulur, hatalı kayıtlar silinir ve gürültü temizlenir.
3) **Özellik Çıkarımı (Feature Engineering):** Ham veriden modelin anlayabileceği anlamlı değişkenler üretilir. (Örneğin; doğum tarihinden "yaş" bilgisini üretmek).
4) **Model Seçimi (Model Selection):** Probleme en uygun algoritma (KNN, Random Forest vb.) belirlenir.
5) **Eğitim (Training):** Verinin büyük bir kısmı (%70-80) algoritma ile buluşturulur. Model, girdi ve çıktı arasındaki ilişkiyi burada öğrenir.
6) **Doğrulama (Validation):** Eğitim sırasında modelin "hiper-parametreleri" ayarlanır. Modelin hiç görmediği bir veriyle performansı kontrol edilerek ince ayar yapılır.
7) **Test:** Modelin nihai başarısını ölçmek için saklanan, modelin daha önce hiç karşılaşmadığı son veri setidir. "Gerçek dünya" provasıdır.
8) **Deployment (Canlıya Alma):** Başarılı modelin gerçek kullanıcılarla buluşmasıdır. Artık model bir uygulama içinde tahmin üretmeye başlar.

Veri Kalitesi

Eksik Veri (Missing Data): Veri setindeki bazı satırların veya sütunların boş olmasıdır. (Örn: Bir anket formunda yaş kısmının doldurulmaması).

Gürültü (Noise): Verideki anlamsız sapmalar veya hatalı ölçümlerdir. (Örn: Bir sıcaklık sensörünün 25°C yerine anlık olarak 100°C ölçmesi).

Dengesizlik (Imbalance): Sınıfların veri setinde eşit dağılmamasıdır. (Örn: Bir kanser teşhis veri setinde 990 sağlıklı, sadece 10 hasta kaydı olması).

Yanlılık (Bias): Verinin toplandığı kaynağın veya yöntemin taraflı olmasıdır. (Örn: Sadece gençlerden veri toplayıp tüm nüfus için tahmin yürütmek).

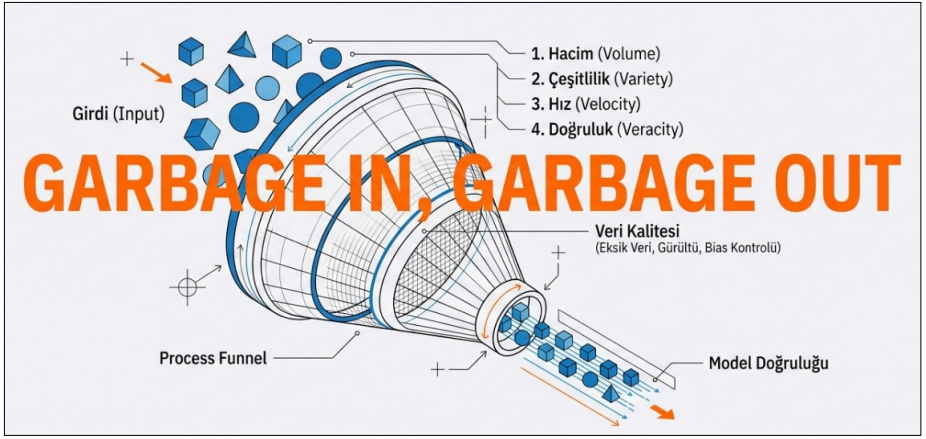

Veri Kalitesi

“Garbage In, Garbage Out” (GIGO)

Bu kavram, makine öğrenmesinin altın kuralıdır. Eğer modelinizi;

- Hatalı (Gürültülü),
- Eksik,
- Veya yanlı verilerle beslerseniz,

Elde edeceğiniz sonuçlar da kaçınılmaz olarak *hatalı ve güvenilmez* olacaktır.

Eğitim ve Test Ayrımı

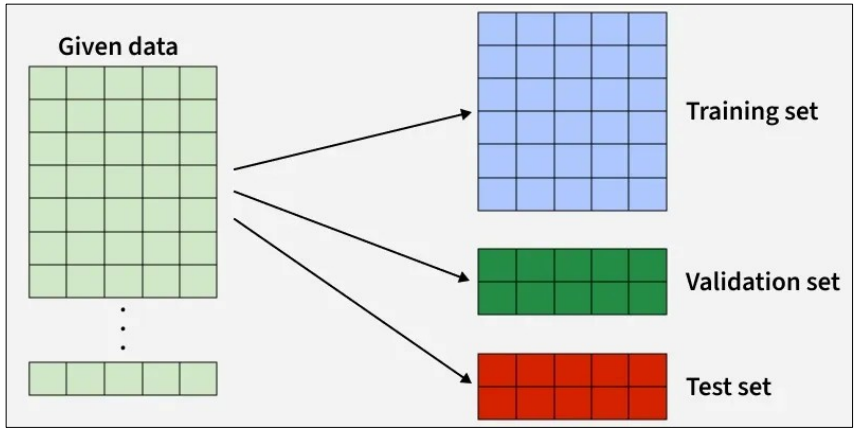

Eğitim Seti (Train Set): Verinin en büyük kısmıdır (%70-80). Modelin “ders çalıştığı”, kalıpları öğrendiği ve parametrelerini güncellediği ana veri grubudur.

Doğrulama Seti (Validation Set): Modelin eğitim sırasında “ara sınavı” gibidir. Modelin performansına bakılarak hiper-parametreler (örneğin öğrenme hızı) burada ayarlanır. Model bu veriyi doğrudan öğrenmez, sadece kontrol amaçlı kullanılır.

Test Seti (Test Set): Modelin eğitimi ve tüm ayarları bittikten sonra karşılaştığı “final sınavı”dır. Model bu veriyi daha önce hiç görmemiştir. Gerçek hayattaki başarısı bu set ile ölçülür.

Overfitting ve Underfitting

Overfitting (Aşırı Öğrenme)

Modelin gürültü ve aykırı değerler de dahil olmak üzere eğitim verilerinden çok fazla şey öğrenmesi durumunda ortaya çıkar. Eğitim verilerinde çok iyi performans gösterirken, test verilerinde kötü performans gösterir. Bu durumun nedenleri şunlardır:

- Model çok karmaşık
- Çok fazla özellik
- Çok az veri
- Düzenleme yok
- Yüksek varyans

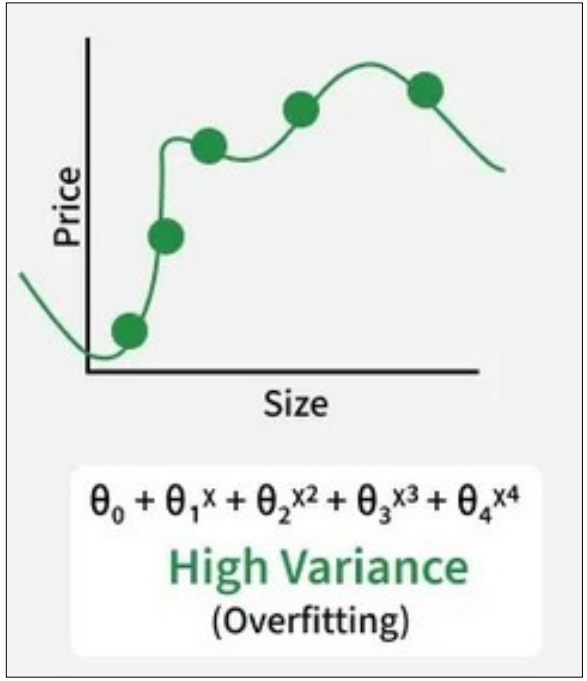

Overfitting ve Underfitting

Underfitting (Eksik Öğrenme)

Modelin önemli kalıpları öğrenememesi durumunda yetersiz öğrenme (underfitting) meydana gelir. Bu durum, modelin hem eğitim hem de test verilerinde düşük performans göstermesine yol açar. Bu durum şu nedenlerden dolayı kaynaklanır:

- Model çok basit
- Çok yüksek düzenleme
- Özellikler zayıf veya eksik
- Yeterli eğitim yok
- Yüksek önyargı

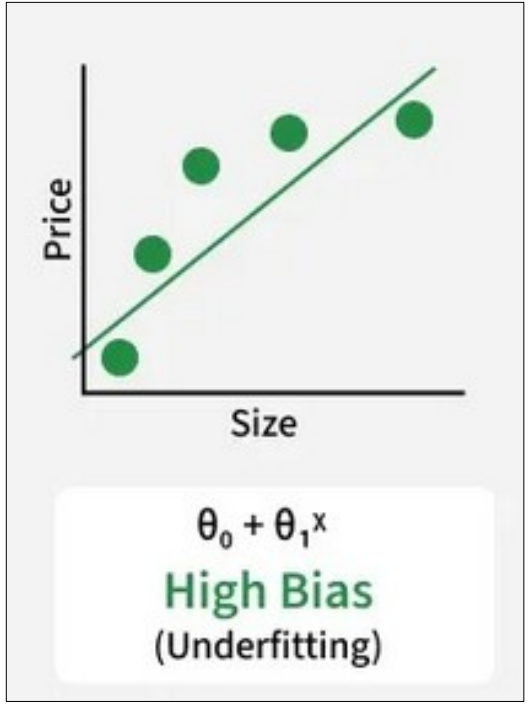

Genelleme

İSTANBUL TİCARET ÜNİVERSİTESİ

Genelleme, bir modelin eğitim aşamasında karşılaştığı örneklerden çıkardığı mantığı, daha önce hiç görmediği (test) verilere başarıyla uygulayabilme yeteneğidir.

$$E_{train} \approx E_{test}$$

Bu ifade, modelin eğitim hatası (Etrain) ile test hatasının (Etest) birbirine çok yakın olması gerektiğini belirtir.

- **Eğer Etrain çok düşük, ama Etest çok yüksekse:** Model genelleme yapamamış, veriyi ezberlemiştir (Overfitting).
- **Eğer her iki hata da yüksekse:** Model yapıyı hiç öğrenememiştir (Underfitting).
- **İdeal Durum (Etrain≈Etest):** Model verideki genel örüntüyü kavramıştır ve gerçek dünyada güvenle kullanılabilir.

Bilgi Temsili Kavramları

- **Vektör Uzayı (Vector Space):** Verilerin sayı dizileri (vektörler) olarak temsil edildiği matematiksel bir düzlemdir. Her bir veri noktası, bu uzayda belirli bir koordinata sahiptir.
- **Embedding (Gömme):** Özellikle kelimeler gibi karmaşık verilerin, aralarındaki anlamsal ilişkileri koruyacak şekilde düşük boyutlu sayısal vektörlere dönüştürülmesidir. (Örneğin; "Kral" ve "Kraliçe" vektörlerinin birbirine yakın olması).
- **Latent Space (Gizli Uzay):** Verinin en temel ve sıkıştırılmış özelliklerinin bulunduğu “görünmeyen” alandır. Model, karmaşık veriyi basitleştirerek buraya hapseder; benzer veriler bu uzayda yan yana gelir.
- **Feature Space (Öznitelik Uzayı):** Modelin girdi olarak kullandığı özelliklerin (boyut, renk, fiyat vb.) oluşturduğu çok boyutlu uzaydır. Karar sınırları bu uzayda çizilir.

Model Nasıl “Anlar”?

İSTANBUL TİCARET ÜNİVERSİTESİ

Bir model, bir kedi resmine baktığında onun yumuşak tüylü, miyavlayan evcil bir hayvan olduğunu bilmez. Onun için o resim sadece belirli dizilimdeki piksellerden ibarettir. Bu durumda “bilinç” yoktur.

Modelin yaptığı şey, devasa veri yığınları içindeki olasılıkları ve tekrarlanan yapıları hesaplamaktır.

- **Korelasyon (İlişki):** “Eğer A ve B pikselleri yan yanaysa, bunun bir ‘kulak’ olma ihtimali %92'dir” gibi istatistiksel çıkarımlar yapar.
- **Matematiksel Optimizasyon:** Önceki slaytlarda gördüğümüz $f(x) \approx y$ formülünü kullanarak, hata payını minimize eden en uygun katsayıları bulur.
- **Tahminleme:** Yeni bir veri geldiğinde, geçmişte öğrendiği istatistiksel dağılıma en yakın olan sonucu “tahmin” olarak döndürür.

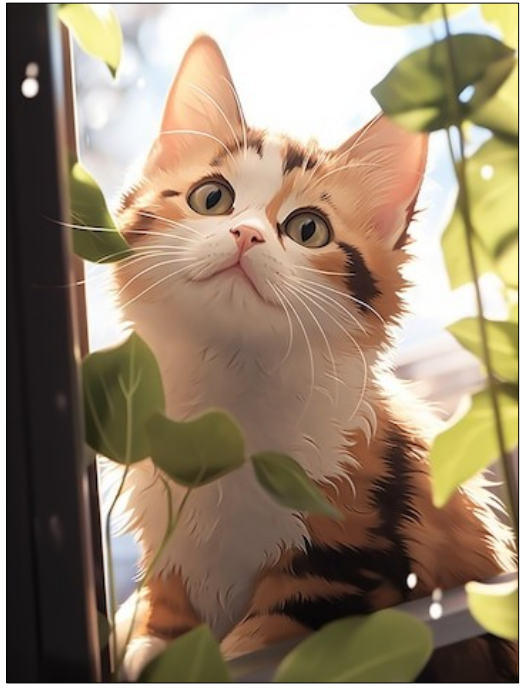

Güncel Araştırma Alanları

İSTANBUL TİCARET ÜNİVERSİTESİ

Günümüzde güncel araştırma alanları;

- **Explainable AI (Açıklanabilir AI):** Karmaşık modellerin verdiği kararların nedenlerini ve nasıl oluştuğunu insanların anlayabileceği şekilde şeffaf hale getirmeyi amaçlar.
- **Federated Learning (Federatif Öğrenme):** Veriyi tek bir merkezde toplamak yerine, verinin bulunduğu cihazlarda (yerel olarak) eğitim yaparak veri gizliliğini koruyan bir öğrenme yaklaşımıdır.
- **Trustworthy AI (Güvenilir AI):** Algoritmaların etik kurallara uygun, tarafsız, siber saldırılara karşı dayanıklı ve her koşulda emniyetli çalışmasını garanti altına almaya odaklanır.
- **Self-supervised Learning (Öz-denetimli Öğrenme):** Dışarıdan bir insan etiketlemesine ihtiyaç duymadan, verinin kendi içindeki yapısal ilişkileri kullanarak öğrenme gerçekleştiren bir yöntemdir.
- **Representation Learning (Temsili Öğrenme):** Ham veriden (ses, görüntü, metin), modelin başarısını artıracak en anlamlı ve öz nitelikli bilgileri otomatik olarak keşfetme sürecidir.

Veri ve Etik Kavramları

İSTANBUL TİCARET ÜNİVERSİTESİ

- **Veri Yanlılığı (Data Bias):** Modelin eğitildiği veri setinin gerçek dünyayı tam yansıtmaması veya tarihsel önyargılar içermesidir. Örneğin, sadece belirli bir etnik kökenden gelen insanların verisiyle eğitilen bir yüz tanıma sistemi, diğer gruplarda başarısız olur.
- **Algoritmik Ayrımcılık:** Yanlı verilerle eğitilen modelin, belirli gruplara (cinsiyet, ırk, yaş vb.) karşı sistematik olarak haksız kararlar vermesidir. Bu durum, işe alım veya kredi başvurusu gibi kritik süreçlerde adaletsizliğe yol açabilir.
- **Model Şeffaflığı:** Bir modelin karara nasıl vardığının izlenebilir ve denetlenebilir olmasıdır. “Kara kutu” modellerin aksine, şeffaf modeller hangi verinin sonucu ne kadar etkilediğini açıkça ortaya koyar.

Kritik Tartışma

İSTANBUL TİCARET ÜNİVERSİTESİ

Makine gerçekten öğreniyor mu, yoksa istatistiksel tahmin mi yapıyor?

Eğer “öğrenmeyi” yeni bir duruma uyum sağlamak ve deneyimden ders çıkarmak olarak tanımlarsak; evet, makineler verideki kalıpları belirleyerek davranışlarını günceller.

Ancak bu öğrenme, insanın "anlamlandırma" sürecinden yoksundur; makine neden-sonuç ilişkisini değil, sadece veriler arasındaki korelasyonu (ilişkiyi) görür.

Bir sonraki kelimeyi veya resimdeki nesneyi tahmin ederken, aslında “bu girdi verildiğinde, geçmiş verilere göre en yüksek olasılıklı çıktı hangisidir?” sorusuna yanıt arar.

Yani makine "elma"yı tanıdığında onun tadını veya kokusunu bilmez; sadece piksellerin “elma” etiketine çıkma ihtimalinin yüksek olduğunu hesaplar.

Özet

- **Veri Odaklılık:** Yapay zekâ veri ile beslenir.
- **Matematiksel Süreç:** Öğrenme, hata payını en aza indirmeyi hedefleyen matematiksel bir optimizasyon problemidir.
- **Kalite Standartları:** Veri kalitesi (temizlik, denge, tarafsızlık), model performansının üst sınırını belirler.
- **Nihai Başarı:** Ezberlemek değil, yeni verilere uyum sağlamak yani “Genelleme”dir.

Kaynakça

- https://www.iso.org/artificial-intelligence/what-is-ai
- https://www.ibm.com/think/topics/artificial-intelligence
- https://www.datacamp.com/blog/what-is-symbolic-ai
- https://gemini.google.com
- https://chatgpt.com/
- https://www.geeksforgeeks.org/artificial-intelligence/expert-systems/
- https://www.youtube.com/watch?v=1f2iQbTE2Ng
- https://getthematic.com/insights/what-is-deep-learning
- https://www.zldoty.com/what-is-machine-learning/
- https://www.wolfram.com/language/introduction-machine-learning/machine-learning-paradigms/
- https://www.geeksforgeeks.org/machine-learning/training-vs-testing-vs-validation-sets/
- https://www.ibm.com/think/topics/ai-data-quality
- https://en.wikipedia.org/wiki/Neural_network_(machine_learning)
- https://www.cloudflare.com/learning/ai/what-is-neural-network/
- https://www.geeksforgeeks.org/machine-learning/underfitting-and-overfitting-in-machine-learning/
- https://www.youtube.com/watch?v=o3DztvnfAJg
- https://www.ibm.com/think/topics/latent-space
- https://datumo.com/glossary/feature-space/
- https://www.ibm.com/think/topics/explainable-ai
- https://zkcplk.medium.com/federe-%C3%B6%C4%9Frenme-federated-learning-nedir-nas%C4%B1l-%C3%A7al%C4%B1%C5%9F%C4%B1r-f104bdf3ea9b
- https://blogs.nvidia.com/blog/what-is-trustworthy-ai/
- https://www.ibm.com/think/topics/data-bias